

基于重复测量建模与条件风险决策的 NIPT 检测时点优化及异常判定

摘要

无创产前基因检测（NIPT）的时点选择需同时处理胎儿游离 DNA 浓度增长、同一孕妇多次检测的相关性以及延迟发现风险；异常判定则面对类别不平衡与少数阳性样本。本文以男胎 1082 条记录、267 名孕妇与女胎 605 条记录、147 名孕妇为对象，按孕妇分组构建“浓度关联解释—达标概率预测—条件风险决策—异常标记判定”的框架，避免将重复测序记录当作独立样本。

对于问题一，在 Y 染色体浓度的 logit 尺度上建立随机截距线性混合模型，并以低维加性样条作非线性对照。孕周系数为 0.04701、BMI 系数为 -0.02446 ，组内相关系数为 0.7283；按孕妇留出的预测决定系数 $R^2 = -0.0302$ 。显著关联与新孕妇个体预测能力被明确区分：孕周、BMI 有群体解释力，但不足以准确预测从未见过的孕妇。

对于问题二，以 Y 浓度是否达到 4% 建立边际达标概率模型（对新孕妇积分随机效应），并把失败风险与延迟代价合成为条件风险，用动态规划在连续 BMI 上联合确定分组与时点。中延迟 M 情景（外部设定的风险权重，不视为医学常数）给出三组条件方案：BMI [20.7, 33.4)、[33.4, 34.4)、[34.4, 46.9] 分别建议 11 周、11 周 6 天、12 周 6 天检测，对应 200、25、42 名孕妇。11 周为搜索域下界，且不晚于 12 周的首次观测仅 69 名孕妇，故该答案绑定阈值与风险情景，不宣称为无条件最优。

对于问题三，加入年龄、身高及孕产代理变量后，基础扩展模型 Brier 为 0.11192，较 Q2 高 0.00032（配对区间跨零），未显示稳定增益；因此保留问题二的简洁主线，多因素方案仅作为条件扩展。

对于问题四，固定阈值 $|Z| \geq 3$ 的常规 Z 值规则在本数据召回率仅 5.97%，不足以独立判定。改以 16 个测序与孕妇特征的 Elastic-Net Logistic 为主模型，采用按孕妇分组的嵌套交叉验证：外层 5 折、内层按主体选正则化强度与判定阈值。外层 AUC 为 0.808 (95%CI [0.756, 0.859])、PR-AUC 为 0.460、Brier 为 0.160；嵌套阈值（各折中位 0.491）下敏感度 68.7%、特异度 77.3%。并给出“质控 $\rightarrow$ Z 值提示 $\rightarrow$ 概率复核”的三级示例判定规则，明确 0.491 与 0.30 两条阈值的来源与局限。

结论适用于本附件、所列阈值与风险情景，不能替代临床确诊或独立队列验证；全套代码与结果可按附录复现清单追溯。

关键词：NIPT；重复测量混合模型；条件风险决策；动态规划；Elastic-Net；概率校准

一、引言

无创产前基因检测（NIPT）以孕妇外周血中的胎儿游离 DNA 为信息来源。与侵入性取样相比，其风险低、易于重复，但结果是否可报告、异常信号是否可检出，与采样时的孕周及胎儿游离 DNA 比例密切相关：孕周过小，浓度不足会导致检测失败或结果不可信；孕周偏大，若存在需要复核或产前诊断的情形，留给临床决策的时间又被压缩。因此，“何时检测”不是单一的浓度最大化问题，而是在浓度增长规律、个体差异与延迟发现代价之间的权衡。另一方面，检测后的结果解读在男胎与女胎中的依据不同：男胎可直接利用 Y 染色体浓度信号，而女胎没有 Y 信号，只能依赖 13、18、21 号染色体及 X 染色体相关的测序统计量与孕妇特征判定非整倍体标记。附件数据以“同一孕妇多次检测”的纵向记录为主，男胎工作表含 1082 条记录、267 名孕妇，女胎工作表含 605 条记录、147 名孕妇。同一孕妇的多条记录并不独立，若按行建模会系统性夸大有效样本量、高估泛化能力，因此全文以孕妇为独立抽样单位。

本文按信息可得的时间顺序组织四个任务。问题一以男胎 Y 染色体浓度为连续响应，在 logit 尺度建立含孕妇随机截距的纵向模型，回答孕周与 BMI 是否与浓度存在可解释的关联；并把“群体关联显著”与“对新孕妇是否可预测”分开陈述。问题二把浓度观测转化为达标事件（达到 4%），先对新孕妇积分随机效应得到边际达标概率，再把失败概率与逐周延迟代价合成为条件风险，在显式风险情景下用动态规划联合划分 BMI 区间与推荐时点。问题三检验在预约前可得变量（年龄、身高及孕产代理变量）中能否找到对问题二决策基础的稳定改进。问题四面向女胎，在检测后特征条件下建立异常标记的概率判定模型，给出可复核的三级示例判定规则，并说明规则阈值的来源与使用边界。

贯穿四问的技术原则有三条。其一，数据层级必须区分孕妇、抽血、测序：重复测量结构通过随机效应刻画，验证划分以孕妇为界，避免同一孕妇的相似记录同时出现在训练与测试集。其二，信息可得时点决定变量能否进入模型：预约决策只能使用预约前信息，而检测后判读可以使用测序质量特征。其三，报告口径与验证口径一致：正文给出的时点与阈值都绑定明确的浓度阈值、风险权重与支持约束，指标都来自按孕妇留出的折外预测，并同时报告不确定性来源（配对区间、重采样、Bootstrap），不把交叉验证的汇总统计量表述为独立验证后的部署结论。

二、总体分析

四个子问题按“关联解释—概率预测—风险决策—异常判定”的链条递进，其统计任务与信息口径各不相同，不能用一个模型通吃。问题一是连续响应上的纵向关联刻画，目标是系数解释与假设检验，验证关心“对新孕妇的固定效应外推是否成立”；问题二把连续浓度二元化为达标事件，预测对象是未见孕妇在某孕周达标的边际概率，验证

关心概率校准与跨孕妇稳定性；问题三在问题二的验证框架上比较协变量规格，属于同折配对比较；问题四则是检测后特征上的不平衡分类，验证必须同时按孕妇分组并处理稀有的阳性标签。四个问题的时间口径不同：前三问只允许使用预约时已知信息（首条记录的 BMI、年龄等），问题四可以使用检测完成后才得到的染色体统计量与质量特征。

方法设计上，本文强调三处对称的处理。其一，训练与验证对称：一切预处理（缺失填补、标准化）、参数选择与阈值选择都只在训练折内进行，折外记录只用于一次评估，杜绝通过“先看全数据再划分”引入的泄漏。其二，报告与口径对称：正文给出的是“本附件、给定阈值与风险情景下”的条件解，敏感性分析展示解随权重、阈值与样本扰动的变化，而不是把某组切点陈述为普适最优。其三，模型复杂度与证据强度对称：只有当候选模型在相同验证下相对当前基线有稳定增益时才升级主模型；样条对照、多因素扩展与阈值规则的比较均未获得足够的稳定证据，故主答案保留结构最简、解释最清晰的规格。

验证层面的总体安排如下。问题一、二、三共用按孕妇分组的固定五折划分，便于问题三在同折上做配对损失比较；问题四采用按孕妇分组、按标签分层的嵌套交叉验证，内层在训练折内选择正则化强度与判定阈值。所有指标（RMSE、 R^2 、Brier、AUC、敏感度/特异度等）都来自折外预测的汇总，Bootstrap 区间描述同一模型规格在主体重采样下的不确定性。分析过程中记录的失败或未通过的候选（如样条的非线性增益偏弱、多因素扩展无稳定增益、固定 Z 阈值召回不足）都保留在支撑材料的实验输出中，正文只陈述其证据含义，不删除失败记录，以保证结论可复核。

三、模型假设

模型假设需要与数据层级、信息可得时点以及验证口径保持一致。若假设在数据上明显不成立，会直接改变结论的解释范围，因此这里逐条说明其理由与局限。

- 预约决策仅使用预约前或首条记录可得的信息，检测后质量变量不进入预约模型。该假设来自任务语义：给孕妇的“建议何时检测”只能在预约时给出，此时尚未产生本次检测的测序统计量。若把检测后信息（读段数、GC 含量、比对比例等）纳入预约模型，就构成对未来信息的穿越式使用。首条记录中的 BMI 等母体特征是预约前可得的代理信息，允许进入模型；但首条记录本身若已携带事后信息（例如本次检测的 Y 浓度）则不使用。该限制只针对预约类任务，问题四的结果解读发生在检测之后，可以使用全部检测特征。

- 同一孕妇的未观测稳定差异由随机截距刻画，给定固定效应和随机效应后残差近似独立。这是对纵向数据最简的相关结构假设：它承认同一孕妇多次检测的测量间存在由个体水平引起的稳定相关（组内相关），但不引入更复杂的时间相关或异方差。残差“近似独立”意味着模型未必能解释同次抽血内技术重复之间的残余波动，

这部分波动单独在问题三的测量误差分析中用重复测序组估计，而不并入随机效应的解释。

- 4% 为主分析浓度阈值，3.5% 和 4.5% 只用于敏感性分析；搜索孕周为 11 至 25 周。4% 是题面给出的可报告性判断依据，并非本文推导出的医学最优值，故正文把 4% 作为主分析口径，同时用相邻阈值检验分组与时点对阈值口径的敏感性；孕周搜索域同样来自题面范围与数据观测支持。阈值与搜索域的改变会平移或改变分组结果，因此正文结论全部绑定“4%、指定风险情景、11–25 周搜索域”这一口径。

- 问题四的异常标签为附件标记，供模型比较，不等同于临床确诊结局。女胎工作表的“染色体的非整倍体”列给出的是标记而非金标准确诊；本文以该标记为学习目标得到的是“预测该标记的概率”，用于展示判别能力与判定流程，不构成临床诊断建议，也不作为患病率或检测性能的流行病学估计。

除上述显式假设外，模型还默认：缺失值机制在训练内可填补且不随孕妇泄漏（预处理见数据审查节）；男胎与女胎两工作表分开建模，不做跨性别信息借用；风险权重（延迟代价与 13 周阶跃惩罚）为分析者指定的情景参数而非估计量，其取值只用于比较方案在权重变化下的稳定性。正文所有“最优”“建议”的表述都以上述假设为界，超出假设范围的解读（如直接迁移到其他人群或作为临床部署阈值）不在本文结论之内。

四、符号说明

表 1 主要符号说明

符号	含义
Y_{ij}	第 i 名孕妇第 j 次检测的 Y 染色体浓度
g_{ij}	检测孕周
b_i	孕妇 i 的随机截距
$p(t \mid x)$	特征 x 下孕周 t 达到浓度阈值的边际概率
$R(t \mid x)$	在孕周 t 检测的条件风险
λ, δ	每周延迟代价与 13 周起附加代价
q_i, h	女胎异常预测概率与分类阈值

五、数据审查与预处理

本节说明为什么把“记录一孕妇”两层结构放在所有建模之前，以及各变量口径如何选择。数据审查中发现的结构性事实（重复测量、左删失、阈值反转）不是可以“清洗掉”的噪声，而是任务本身的一部分：它们决定了该用哪种概率对象、哪类验证以及结论应如何措辞。

5.1 数据层级与样本结构

男胎工作表包含 1082 条测序记录、267 名孕妇；女胎工作表包含 605 条记录、147 名孕妇。男胎每位孕妇有 1 至 8 条记录，中位数为 4 条。同一孕妇可能在不同时间重复抽血，也可能在同次抽血下重复测序；前者同时包含随孕周变化和个体差异，后者更接近检测过程波动。图 1 显示重复记录数量，说明记录数不能直接当作独立样本量。

若忽略主体结构把每条记录当作独立样本，会产生三方面问题。其一，样本量被夸大：真正的样本单位是孕妇，记录只是其重复观测，按行计算的置信区间会系统性偏窄。其二，测试集泄漏：同一孕妇在不同孕周的记录高度相关，若其部分记录进入训练集，其余记录进入测试集，则”新个体外推”被偷换成”同一人的内插”。其三，统计推断的对象错位：逐行回归估计的是”记录层面”的关联，而题目关心的是”孕妇层面”的决策对象。因此本文在数据层面对齐了三个层次：孕妇为随机抽样单位（用于分组与验证）、抽血批次为中间层（时间变化来源）、测序记录为观测层（技术波动来源）。

表 2 数据结构与阈值观测概况

项目	数值	建模含义
男胎记录 / 孕妇	1082 / 267	主体分组验证
女胎记录 / 孕妇	605 / 147	稀有标签与主体相关并存
男胎每人记录数	1-8，中位数 4	不得假设独立同分布
Y 浓度达到 4%	937 条	达标记录占多数
Y 浓度低于 4%	145 条	保留为早检失败风险信号
首次观测已达标	217 名孕妇	首次达标时间左删失
观察到未达标转达标	43 名孕妇	事件仅能定位于区间
阈值反转	34 名孕妇	达标状态并非严格单调




图 1 男胎孕妇的重复记录数量分布

表 2 中后三行直接关系到问题二的口径。”首次观测已达标”的 217 名孕妇说明：附件记录的是”观测时点是否达标”，而不是”生理上首次达标的时刻”——对这部分孕妇，我们只知道其首条记录已经达标，真实达标时刻可能更早（左删失）。”观察到未达标转达标”的 43 名孕妇提示达标事件在随访期间确实会发生，但其首次达标只能定位到两次检测之间的区间。34 名孕妇出现阈值反转（曾达标后又低于阈值），说明把达标状态当作严格单调事件并不稳健。这三类现象共同决定了问题二回答”在给定孕周做一次检测是否达标”的可观测问题，并明确不做”首次达标时刻”的强推断。

5.2 变量口径与信息泄漏防范

孕周统一为连续周数，即整数周加天数除以 7；优化输出再换回“周和天”。百分比变量统一为 0 至 1 比例，4% 对应 0.04。BMI 与身高、体重用于一致性审查，但不在小样本模型中无条件同时使用高度共线变量。原始附件不改写，派生变量全部由代码生成。

口径选择有两条一致原则。其一是时间一致性：所有变量都必须映射到它实际被知晓的时刻。BMI 取孕妇首条记录值，作为”预约前可得的个体特征”代理；同一孕妇的后续记录只提供纵向响应，不反向填充预约时未知的协变量。其二是单位一致性：浓度比例在 0 到 1 之间取值，直接建模会受到边界约束，故对响应做 logit 变换后再进入线性混合模型；而百分比阈值（4%、3.5%、4.5%）在建模与报告中统一为 0–1 比例，避免”0.04”与”4”混用造成数量级错误。

预约时点模型只能使用预约时已知信息。读段数、过滤比例、GC 含量等属于检测后信息，不进入 Q2 和 Q3。Q2 使用每位孕妇首条记录 BMI 作为预约前代理，Q3 使用相同基线时点的年龄、身高等变量；这避免将未来记录带入早期预约，但仍是回顾性代理。女胎异常任务不同：其输入在检测后判定时已可获得，故可以使用染色体统计量及测序质量特征。此处区分的不只是变量清单，而是两种决策的语义：预约是前瞻决策，未来信息不可用；判读是回顾决策，检测过程本身产生的信息可以用于结果解释。泄漏

防范落实为代码层的三处强制：分组交叉验证的划分只依据孕妇编号；任何缺失填补、标准化、变量筛选都在训练折内估计；OOF 预测在模型定型后一次性生成，不参与后续调参。

六、模型的建立与求解

6.1 问题一：Y 染色体浓度的重复测量模型

男胎数据含 1082 条记录、267 名孕妇（与表 2 口径一致）。将浓度比例作 logit 变换，主模型为

$$z_{ij} = \beta_0 + \beta_1 g_{ij} + \beta_2 \text{BMI}_{ij} + \beta_3 g_{ij} \text{BMI}_{ij} + b_i + \varepsilon_{ij}, \quad b_i \sim N(0, \sigma_b^2). \quad (1)$$

孕周系数为 0.04701、BMI 系数为 -0.02446 ，交互项没有稳定证据。组内相关系数 0.7283 表明主体层级不可省略。以孕妇为组作五折外层验证，主模型 $R^2 = -0.0302$ ；因此显著关联不被解释为对新个体的精确预测。




图 2 BMI 对 Y 染色体浓度的边际影响

6.1.1 系数解释、模型对照与结论边界

表 3 给出固定效应估计。孕周的 95% 区间为 $[0.04214, 0.05187]$ ，BMI 的 95% 区间为 $[-0.04018, -0.00874]$ ；孕周与 BMI 交互项区间跨零，故不把它解释为已经证实的调节机制。随机效应模型的条件拟合 R^2 约为 0.7890，但它使用了已观测孕妇的历史记录来估计其随机截距。该数值不能替代新孕妇的外层预测 R^2 。

表 3 Y 浓度混合模型的固定效应估计

项	系数	95% 区间	p 值
截距	-2.57364	[-2.62810, -2.51918]	—
中心化孕周	0.04701	[0.04214, 0.05187]	4.57×10^{-80}
中心化 BMI	-0.02446	[-0.04018, -0.00874]	0.00229
孕周 $\times$ BMI	0.00120	[-0.00022, 0.00262]	0.09680




图 3 孕周与 Y 染色体浓度的模型关联曲线

为检验线性设定，以低维自然三次加性样条替代线性孕周、BMI 项，仍保留孕妇随机截距；样条自由度仅在外层训练集内选择。表 4 显示样条的记录级误差略低，但主体平均误差差异很小，故保留线性混合模型作为主解释工具。它的优势是关系清晰，而不是宣称其个体预测充分准确。

对表 4 需要说明比较对象与口径。误差按“记录级”与“主体平均”两个层面汇总：记录级 RMSE 把每条观测视作一个误差项，主体平均 RMSE 先把同一孕妇多条预测误差平均再汇总，后者与新孕妇决策的口径一致。两种模型在主体平均口径上的差异远小于各自的验证不确定性，说明样条带来的增益主要体现在对已观测孕妇记录的重新拟合上，而对“未见孕妇”的外推没有实质改进。这与正文的结论分层一致：线性混合模型作为关联解释的主模型是出于清晰与稳健，不是因为它具备更强的个体预测能力。因此问题一的最终表述同时给出三层信息——显著系数（关联存在）、条件拟合表现（对已知孕妇）与主体留出外推表现（对未知孕妇），避免把任一层单独陈述为问题一的完整答案。

在模型设定层面还处理了两个细节。其一，孕周与 BMI 都做了中心化处理，使截

距对应平均孕周、平均 BMI 处的预测，固定效应系数可直接解读为在该中心点的边际斜率，同时降低交互项与主效应之间的数值相关性；表 3 报告的就是中心化口径下的估计。其二，对数几率（logit）变换将浓度比例 (0, 1) 映射到实数轴，避免线性模型预测越出可行区间，也使方差结构在变换尺度上更接近正态假设；报告时若需要浓度比例尺度上的直观解释，可用逆变换回推典型取值，但本文的推断、区间与验证都发生在 logit 尺度上，不作尺度间的乐观外推。

表 4 问题一的新孕妇预测比较

模型	记录 RMSE	记录 MAE	记录 R^2	主体平均 RMSE
线性混合模型	0.51406	0.42321	-0.03023	0.50628
加性样条混合模型	0.50717	0.41598	-0.00278	0.50083

6.2 问题二：达标概率、风险函数与 BMI 分组

问题二在建模上分三步走，每一步对应一个明确的概率或决策对象，避免把”预测达标概率”与”决定何时检测”混为一个黑箱。第一步先定义事件：对男胎第 i 名孕妇第 j 次记录，令达标事件 $A_{ij} = I(Y_{ij} \geq 0.04)$ ，即该次检测的 Y 浓度比例是否达到 4%。由于同一孕妇存在多条记录且个体间存在稳定差异，简单地对全部记录拟合一个不含随机效应的二项模型，等价于假设给定孕周与 BMI 后各次检测相互独立，这与表 2 显示的重复测量结构相矛盾。因此在 logit 连接下拟合带随机截距的二项混合模型，用随机截距吸收同一孕妇跨记录的相关。

第二步给出面向”新孕妇”的概率对象。混合模型估计的是条件概率 $\text{logit}^{-1}\{\eta(t, x) + b_i\}$ ，其中随机截距 b_i 是针对已知孕妇的。要回答”一名我们从未见过、特征为 x 的孕妇在孕周 t 检测达标的概率”，必须对随机效应的总体分布求平均，得到边际达标概率：

$$p(t | x) = \int \text{logit}^{-1}\{\eta(t, x) + b\} \phi(b; 0, \sigma_b^2) db. \quad (2)$$

其中 x 为 BMI。式 (2) 与”把随机截距直接设为零”的条件概率不同：后者忽略了孕妇间差异的混合作用，在非线性连接下系统性低估或高估平均概率；本文按随机效应分布的数值积分（Gauss-Hermite 类方法）计算边际概率，使其对应于随机抽取一名新孕妇的平均达标机会，与正文按孕妇分组的外层验证口径一致。

第三步把概率转化为决策成本。仅知道达标概率并不足以给出时点建议，因为”早检未达标”与”晚检才出结果”的成本不对称。定义条件风险

$$R(t | x) = 1 - p(t | x) + \lambda(t - 11) + \delta I(t \geq 13). \quad (3)$$

其中第一项是本次检测未达标的失败风险，后两项刻画等待代价：每延迟一周增加 λ 的代价，孕周到达 13 周后再追加 δ 的阶跃惩罚，用于体现”若需产前诊断等后续程序，

可执行时间被压缩”的延迟成本结构。式 (3) 中的 λ, δ 是外部指定的风险情景参数而非数据估计量，因此求解结果必然依赖其取值。低延迟 L、中延迟 M、高延迟 H 分别取 $(\lambda, \delta) = (0.005, 0.10)$ 、 $(0.020, 0.10)$ 、 $(0.050, 0.10)$ 。本文选择 M 作为主答案：它同时保留失败和等待代价，避免 L 情景频繁出现 25 周边界解，也避免 H 情景将方案推向 11 周边界。

在逐孕周风险的基础上，还需要回答”给谁建议什么时点”。直接对每名孕妇单独给最优周会得到大量互不相同的时点，不利于服务组织，因此题目要求按 BMI 分组给出统一建议。把 267 名男胎孕妇按 BMI 排序后，问题化为把排序序列切成若干连续段、并为每段选择一个公共检测时点，使组内加权风险最小；同时施加可操作约束：每段至少包含最小组样本量，相同 BMI 取值不跨段拆分，且所选时点附近必须有足够观测支持（避免在无数据区域外推）。动态规划的递推式及其求解细节见后文”概率验证、可行性与动态规划”小节。表 5 给出 4% 阈值、M 情景的有效三组解；边界显示到一位小数，优化使用未舍入值。

表 5 问题二：4% 阈值、中延迟 M 情景下的条件方案

BMI 区间 (kg/m^2)	人数	推荐检测时点	说明
[20.7, 33.4)	200	11 周	搜索域下界
[33.4, 34.4)	25	11 周 6 天	满足最小组样本量
[34.4, 46.9]	42	12 周 6 天	13 周阶跃之前




图 4 不同孕周与 BMI 下的边际达标概率

6.2.1 概率验证、可行性与动态规划

真实首次达标周在附件中不能直接识别：217 名孕妇首次观测时已达标，43 名在随访中才观察到由未达标转达标，另有 34 名出现阈值反转。因此本问回答可观测问题“在某孕周的一次检测是否达标”，而不将首次观测时点误称为生理首次达标时点。

外层五折以孕妇分组；每名孕妇先平均其记录 Brier 损失，再跨孕妇平均，避免多次检测者权重过大。二项模型主体 Brier 为 0.11160，训练主体常数率基线为 0.11315，提升较小；校准图的高概率区域也存在一定乐观偏差。图 5 和图 6 分别展示 BMI 条件的概率曲线与早孕支持范围；不晚于 12 周的首次观测仅 69 名，故早期策略不能被解读为无条件外推。




图 5 不同 BMI 条件下的男胎达标概率曲线




图 6 男胎检测孕周与首次观测时点的支持范围

对排序后的主体，令 $C(a, b)$ 为第 a 至 b 名主体在共同检测时点下的最小加权风险。动态规划递推为

$$D(k, b) = \min_{a \leq b} \{D(k-1, a-1) + C(a, b)\}, \quad (4)$$

其中候选段必须满足最小主体数、相同 BMI 不拆分和局部观测支持约束。求解后将相邻且时点相同的段合并；保留无决策差异的切点只会制造“越分越细”的假象。全样本条件解与外层概率验证分别报告：前者给出题目要求的可执行方案，后者检验其概率基础的可推广程度。

6.3 问题三：多因素扩展与条件方案

基础扩展规格加入首条记录年龄、身高；完整规格再加入辅助受孕、孕次与产次代理。原体重、身高和 BMI 不同时输入基础规格，检测后质量变量不进入预约模型。三种规格采用相同主体五折划分，以每名孕妇的外层 Brier 损失作配对比较，见表 6。

表 6 多因素固定规格相对 Q2 的主体留出表现

规格	主体 Brier	相对 Q2 差值	差值 95% 区间
Q2: 孕周与 BMI	0.11160	0	—
基础扩展：加入年龄、身高	0.11192	0.00032	[−0.00247, 0.00312]
完整扩展：再加孕产代理	0.11384	0.00224	[−0.00132, 0.00596]

两种扩展均未显示稳定改善。基础扩展在 M 情景下仍按 BMI 分组，得到 [20.7, 33.4)、[33.4, 35.0)、[35.0, 46.9] 三组，推荐时点依次为 11 周、12 周 2 天、12 周 6 天；它是条件扩展结果，不替代问题二的主方案。

6.3.1 配对验证与测量误差敏感性

Q2、基础扩展和完整扩展使用相同的主体五折划分，故可对每名孕妇的外层 Brier 损失作配对比较。图 7 展示两种扩展相对 Q2 的误差差值；正值表示扩展模型更差。区间通过主体损失差值的重采样构造，描述已固定模型规格下的验证不确定性，而不包含反复搜索变量组合带来的全部不确定性。




图 7 多因素扩展相对 BMI 模型的主体配对误差

为评估测量不确定性，按孕妇、检测日期、抽血次数和孕周识别同次抽血重复测序组，共 18 组、14 名孕妇、每组两条记录。在 logit 浓度尺度上，以组内平方和除以自由度估计波动方差：

$$\hat{\sigma}_m^2 = \frac{\sum_g \sum_{j=1}^{n_g} (z_{gj} - \bar{z}_g)^2}{\sum_g (n_g - 1)}. \quad (5)$$

得到 $\hat{\sigma}_m = 0.123745$ ；按 14 名孕妇进行 2000 次重采样，尺度区间为 $[0.08175, 0.16770]$ 。该值是同次抽血组内波动尺度，不是整个 NIPT 平台的仪器误差标准差。

从 267 名男胎孕妇有放回重采样，保留每位被抽中主体的全部记录；对 logit 浓度附加 $c\hat{\sigma}_m\xi_{ij}$ ，其中 $c \in \{0, 0.5, 1, 1.5\}$ ，再重新拟合、重新分组。共完成 20 轮、4 个噪声水平、2 种概率规格的 160 次拟合。表 7 显示低延迟情景下主体平均推荐孕周的实际范围；不同噪声水平的中位数并不单调，不能概括为“误差越大越应提前检测”。

表 7 低延迟情景下主体平均推荐孕周的 20 轮分布

模型	追加噪声倍数	中位数 / 周	实际范围 / 周
Q2	0	14.95	12.86–23.82
Q2	0.5	15.02	12.81–23.82
Q2	1.0	14.43	12.08–25.00
Q2	1.5	14.77	11.65–23.82
基础扩展	0	15.27	12.86–25.00
基础扩展	0.5	15.27	12.71–23.73
基础扩展	1.0	14.88	12.13–25.00
基础扩展	1.5	14.68	11.61–23.82

6.4 问题四：女胎异常标记的概率判定

女胎孕妇无 Y 信号，需从测序统计特征判定 13、18、21 号染色体异常。首先按“染色体的非整倍体”列构造任一异常标签 A_{any} ：67 条阳性记录、44 名独立阳性孕妇（29.9%），类别高度不平衡；同一孕妇多次检测，故验证必须以孕妇为分组单位，防止泄漏。

6.4.1 规则基线：Z 值规则的失效

临床常用 $\max(|Z_{13}|, |Z_{18}|, |Z_{21}|) \geq 3$ 判定异常。本数据中该规则仅召回 67 例阳性中的 4 例（5.97%），同时产生 41 例假阳性；以连续 Z 值评分计算的 AUC 仅 0.479。原因在于异常样本的 Z 值大多未超 3，且 GC 含量偏移对读段计数有系统影响，固定阈值不适合本数据。

6.4.2 Elastic-Net 主模型与嵌套验证

输入 16 个特征：13/18/21/X 染色体 Z 值与 GC 含量、X 染色体浓度、比对/重复/过滤比例、log 读段数、BMI 与年龄。以带类别平衡权重的 Elastic-Net Logistic 为主模型：

$$\min_{\beta} -\frac{1}{n} \sum_i w_{y_i} \{y_i \ln p_i + (1 - y_i) \ln(1 - p_i)\} + \lambda(0.5\|\beta\|_1 + 0.25\|\beta\|_2^2), \quad (6)$$

其中 $C = 1/\lambda$ 与判定阈值 τ 仅由内层训练折选择。验证设计：外层 StratifiedGroupKFold 5 折（按孕妇分组并按标签分层），内层 3 折主体分组选择 C （PR-AUC 最大）与 τ （F2 最大）；外层测试折不参与填补、标准化、拟合或阈值选择。预处理（标准化、中位数填补）嵌入训练管线，只在训练折内估计。

6.4.3 外层结果与校准

表 8 汇总外层 OOF 指标。ROC-AUC 0.808（主体 Bootstrap 95%CI [0.756, 0.859]）、PR-AUC 0.460、Brier 0.160（CI [0.145, 0.176]）。各折内层所选阈值的汇总中位数为 0.491，在该嵌套阈值下敏感度 68.7%、特异度 77.3%。随机森林对照训练 AUC 为 1.000（过拟合），不作主模型。

表 8 问题四：A_any 外层 OOF 汇总指标（Elastic-Net，嵌套阈值）

指标	数值	备注
ROC-AUC	0.808	主体 Bootstrap 95%CI [0.756,0.859]
PR-AUC	0.460	类别不平衡敏感
Brier	0.160	95%CI [0.145,0.176]
嵌套阈值 τ 中位	0.491	各折自选，非全局
敏感度 / 特异度	68.7% / 77.3%	嵌套阈值下
PPV / NPV	27.4% / 95.2%	




图 8 问题四外层 ROC 与 PR 曲线

校准采用固定分箱描述：图 9 显示概率与观测率大体一致，高概率段（>0.95）略偏乐观且箱内样本少，解读需结合支持人数。




图 9 问题四 A_any 概率校准（固定分箱，记录级描述）

6.4.4 特征贡献

表 9 给出 5 个外层折最终模型标准化系数的中位数（按绝对值取前 6）。GC 含量类特征与 X 染色体浓度贡献最大，三条异常染色体的 Z 值系数反而较小——与 Z 规则失效的原因一致；此处仅报告判别贡献，不作因果推断。

表 9 Elastic-Net 标准化系数（5 折中位数，绝对值前 6）

特征	系数	特征	系数
21 号染色体 GC 含量	-2.151	18 号染色体 GC 含量	+0.768
13 号染色体 GC 含量	+1.687	年龄	-0.378
X 染色体浓度	-0.930	被过滤读段比例	+0.303

6.4.5 三级判定规则（示例规则，含阈值来源）

在上述交叉验证结果上构造如下三级流程。该流程是**基于当前交叉验证构造的示例规则**，阈值未经独立队列确认，正式部署前应在训练层显式优化并以外部数据复核。

- **第一级（质控）**：GC 含量超出 [35%, 65%]、比对比例或过滤比例异常者判为无效，建议重新采血；
- **第二级（Z 值提示）**： $|Z_{13}|, |Z_{18}|, |Z_{21}|$ 任一 ≥ 3 标记为高危提示并进入第三级复核（该规则本数据召回率仅 5.97%，不作最终判定门）；
- **第三级（模型判定）**：高危线 $\tau^* = 0.491$ 取各外层折内层所选阈值的中位数（OOF 敏感度 68.7%、特异度 77.3%）；复查线 0.30 取冻结 OOF 上敏感度约 85% 的

操作点（特异度约 54%、NPV 约 96.7%）。即 $p \geq 0.491$ 判异常高危、建议产前诊断； $0.30 \leq p < 0.491$ 判需复查； $p < 0.30$ 判低危、常规随访。

口径说明： $\tau^* = 0.491$ 是交叉验证的汇总统计量，**不等于**全数据重优化并经独立验证的部署阈值；0.30 是按“敏感度优先”选取的操作点而非拟合产物。若更重特异度可将复查线上移（0.35 对应敏感度 80.6%、特异度 59.4%），本文不宣称唯一选择。

6.5 结果解释与时点决策

问题一中，随机效应引入的主体内相关性表明，常规逐行回归会错误放大有效样本量。图 10 比较线性混合模型和样条对照的外层表现：两者均未得到正的主体留出 R^2 ，因此选择线性混合模型作为关联解释的主模型，而不以复杂曲线追求表面拟合度。




图 10 问题一模型在主体留出验证中的比较

问题二的三组时点来自达标概率、风险权重和支持约束的共同作用，而非 BMI 本身的临床分类边界。图 11 显示主体留出概率校准情况；早孕及高 BMI 区域的支持较少，故策略不会在缺乏观测支持的区域作无约束外推。对不同风险权重，L 情景更重视等待、但会在部分组产生 25 周边界解；H 情景更重视延迟、因而倾向于 11 周边界。M 情景位于两者之间，故用于主答案。




图 11 问题二边际达标概率的主体留出校准

问题三的扩展模型将个人年龄、身高代入概率后仍只按 BMI 排序分组，并在组内对实际协变量分布的风险求和；这避免把所有人固定为平均年龄和身高。图 12 展示 M 情景下的扩展条件解以及 L/M/H 场景下的变化。由于表 6 的配对区间跨过零，正文不把它解释成对 Q2 的优越替代。




图 12 问题三多因素扩展下的 BMI 条件时点

6.6 问题四的判定口径

为把问题四的结果从“一组指标”落成“可执行的判定流程”，还需要把概率分数映射到行动，并交代这一映射的证据边界。这里面临两类口径：一是统计口径（用什么概率、按什么验证得到），二是决策口径（概率多高算高危、多高算需复查），二者必须分开说明，否则会误把交叉验证的汇总阈值当成经过独立验证的部署参数。问题四以“任

一异常标记”(A_any)为主线给出可执行判定,同时明确其口径边界。Brier 分数定义为

$$\text{Brier} = \frac{1}{N} \sum_{i=1}^N (q_i - A_i)^2. \quad (7)$$

外层指标 (AUC、PR-AUC、Brier 及 Bootstrap 区间) 与嵌套阈值已在问题四节给出; 此处强调两点: 其一, $\tau^* = 0.491$ 为各折阈值的汇总中位数, 属交叉验证口径, **不等于**在全数据上重新拟合并独立验证的部署阈值; 其二, 复查线 0.30 (或按特异度偏好取 0.35) 是按“敏感度优先”选择的操作点, 不是模型拟合所得。真实临床使用前, 需在独立队列上重新估计阈值, 并把漏诊代价写入目标函数。

为什么采用” 阈值汇总” 而不是” 重拟合一次定阈值”? 原因在于样本量: 女胎阳性孕妇仅 44 名, 若先看全数据再选阈值, 再把同一批数据报告为阈值性能, 会明显高估。嵌套交叉验证让每一折的内层只在训练主体上选择阈值、外层评估该阈值对未见主体的表现, 最后把各折内层所选阈值的中位数作为汇总统计量报告。这种做法的代价是阈值本身带有验证方差, 因此正文在三级规则中同时报告了 0.30 与 0.35 两条候选线及各自权衡, 并把” 正式部署前必须用独立队列重新估计” 写为使用前提, 而不是宣称存在唯一正确的全局阈值。

七、模型检验与分析

检验不是事后的” 加分动作”, 而是本文每个结论成立范围的组成部分。本节把四问的验证设计归为三类可复核的检验: 主体隔离验证回答” 模型对没见过的人是否仍然有效”; 阈值、风险与测量敏感性回答” 结论在口径变化下是否稳健”; 数字的可追溯性由固定种子、输入哈希与复现清单保证, 使每一处报告的数字都能沿” 数据—代码—输出一论文” 链条回查。

7.1 主体隔离验证

问题一的负外层 R^2 说明关联与预测应分开表述。问题二检验概率校准, 问题三以同折损失差值比较, 问题四使用按孕妇分组的嵌套主体隔离阈值选择。由此避免了同一孕妇的相似记录同时出现于训练集和测试集造成的性能高估。

主体隔离验证的共性在于” 划分边界与使用边界一致”。本文所有五折划分都只依据孕妇编号, 且划分在建模前一次固定: 训练折内的记录只用于估计与调参, 测试折内的记录只有在模型定型后才出现一次, 用于计算折外指标。任何需要数据驱动的决定——样条自由度、正则化强度、判定阈值——都被限制在训练折内完成, 以避免” 用测试信息反选模型” 造成的乐观偏差。需要说明的是, 主体隔离解决的是重复测量造成的样本重叠问题, 并不消除另两类不确定性: 模型规格选择的不确定性与测量误差带来的

扰动，这两类分别由问题三的配对区间和测量敏感性检验刻画，不能只靠一次主体划分就宣称结论稳健。

7.2 阈值、风险与测量敏感性

同次抽血重复测序组给出 logit 浓度波动尺度 $\hat{\sigma}_m = 0.123745$ 。按孕妇 2000 次重采样的区间约为 [0.08175, 0.16770]。在 20 轮主体重采样及四档追加噪声下重新拟合和优化，策略随样本构成而变化，故 BMI 切点只代表本附件、当前代价下的条件分割。表 10 显示 Q2 在低延迟 L 情景下对阈值本身的敏感性，进一步说明分组结论必须绑定阈值与风险权重。

表 10 Q2 低延迟 L 情景的阈值敏感性

浓度阈值	有效组数	内部 BMI 切点	检测时点	对应人数
3.5%	1	无	12 周 6 天	267
4.0%	2	33.8	12 周 6 天； 25 周	212； 55
4.5%	2	29.1	12 周 6 天； 25 周	38； 229

问题四阈值的稳定性由嵌套设计与 Bootstrap 描述：ROC-AUC 95%CI [0.756, 0.859]、Brier 95%CI [0.145, 0.176]（表 8）；两条示例阈值的敏感度/特异度权衡已在问题四节说明，需按用途与独立数据复核。

八、模型的评价

评价既要总结模型做到了什么，也要明确它没有做到什么，二者共同决定结论的可迁移范围。

模型的优点可以归纳为三层。第一层是数据结构的诚实处理：模型将孕妇、抽血和测序记录分层，用随机截距刻画重复测量相关，验证以孕妇为界，避免重复记录造成虚假的独立样本量，也避免同一孕妇的记录横跨训练与测试折的性能高估。第二层是决策逻辑的可追溯性：将浓度关联、达标概率和风险优化拆成三个明确的概率/决策对象，使每个推荐时点都可以逐项回推到阈值、风险权重与可行性约束，而不是一个”端到端黑箱”的输出；问题二给出的三组时点能明确说出它依赖的 4% 阈值、M 情景权重、最小组样本量与观测支持规则，便于评审核对或在权重变化时重算。第三层是口径一致性：预处理、参数选择与阈值选择均在训练主体内完成，折外记录只评估一次；报告同时给出条件表现与主体留出表现、点估计与 Bootstrap 区间，避免把”拟合好”误报成”泛化好”。

模型的局限同样需要如实陈述。其一，风险权重 λ, δ 由外部情景指定而非临床效用标定，因此三组时点只在“该权重可接受”的前提下成立，换一组代价就可能改变分组与推荐周；正文选择 M 情景并同时报告 L/H 的变化，正是为了把这种依赖显式化。其二，数据覆盖有边界：早孕（不晚于 12 周的首次观测仅 69 名孕妇）与高 BMI 区域支持较少，女胎阳性仅 44 名孕妇，极端区域的策略与指标带有较大验证方差，正文不作无条件外推。其三，女胎异常标签来自附件标记而非确诊结局，所有 AUC、敏感度等数字描述的都是“对标记的判别”，不是对临床结局的诊断性能。其四，问题四的两条示例阈值是以交叉验证汇总得到的，必须以独立队列重新估计和验证后才能作为部署阈值，直接使用会混淆“验证口径”与“临床决策口径”。

九、模型的改进与推广

改进的方向应指向当前局限对应的数据与信息缺口，而不是在现有数据上堆叠复杂度。最直接的一类改进是补充预约前的基线信息：若能在决策前获得更完整的孕产史、用药史或既往妊娠结局，Q2/Q3 的个体分层会更细，但新变量仍必须通过“同折配对比较是否带来稳定增益”的门槛，而不是因为“有道理”就直接进入主模型。第二类改进是收集早孕期的独立队列与更多高 BMI 孕妇，扩充目前观测支持薄弱的区域；测量误差方面，若获得同次抽血的更多重复测序样本，可把 $\hat{\sigma}_m$ 的估计从 18 组、14 名孕妇扩展到更精确的尺度并检验异方差。第三类改进是针对问题四：取得经过产前诊断或随访确认的结局标签与更大的阳性样本后，才能在独立数据上重新估计阈值并把漏诊/误诊代价显式写入目标函数，从而把本文的示例规则升级为经过部署验证的判定规则。

方法层面，本文建立的“纵向关联解释—边际概率预测—条件风险决策—不平衡分类判读”框架具有可迁移性。在推广时，必须重新定义四个要素而不是照搬参数：可用信息时点（哪些变量在决策前可得）、事件阈值（4% 只是本题口径）、主体单位（孕妇、抽血还是测序取决于决策对象）以及风险权重（由具体应用的延迟成本决定）。只要这四个要素在新任务中被重新设定，同一套主体分组验证、嵌套调参与同折配对的流程即可用于复检预约、连续生理指标随访或筛查流程优化等场景；反过来说，任何不加条件地把本题 BMI 切点或分类阈值移植到其他人群的做法，都不在本文建议范围内。

参考文献

- [1] Wang E, Batey A, Struble C, et al. Gestational age and maternal weight effects on fetal cell-free DNA in maternal plasma. *Prenatal Diagnosis*, 2013, 33(7): 662–666.
- [2] Laird N M, Ware J H. Random-effects models for longitudinal data. *Biometrics*, 1982, 38(4): 963–974.

- [3] Yang J, Ding X, Zhu W. Improving the calling of non-invasive prenatal testing on 13-/18-/21-trisomy by support vector machine discrimination. *PLOS ONE*, 2018, 13(12): e0207840.
- [4] Efron B. Bootstrap methods: Another look at the jackknife. *The Annals of Statistics*, 1979, 7(1): 1–26.
- [5] Zou H, Hastie T. Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society: Series B*, 2005, 67(2): 301–320.
- [6] Brier G W. Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 1950, 78(1): 1–3.

附录

正文所有可报告的数字都来自随论文提交的支撑材料：各实验以 ‘results/’ 下的复现清单（含输入文件 SHA-256、随机种子与唯一运行命令）绑定代码与输出，‘outputs/’ 下的 `experiment.json` 记录参数与汇总结果，‘figures/’ 提供正文插图的 PNG/SVG 原件。下表列出正文各问对应的唯一可运行入口；按附录文件表顺序执行即可复现从原始附件到论文数字的完整链条。附件与代码均为只读/固定版本，重跑结果以 ‘outputs/’ 中已提交的文件为准。

表 11 论文支撑材料及可复现入口

文件	说明
<code>src/q1_lmm_baseline.py</code>	问题一随机截距线性混合模型与固定效应表
<code>src/q1_spline_comparison.py</code>	问题一样条对照的主体留出验证
<code>src/q2_probability.py</code>	问题二边际达标概率与动态规划策略
<code>src/q23_measurement_sensitivity.py</code>	同次抽血波动尺度、主体重采样与噪声敏感性
<code>src/q4_model.py</code>	问题四 Elastic-Net 主模型（嵌套主体分组验证）
<code>src/q4_coef_export.py</code>	问题四各折最终模型标准化系数导出
<code>outputs/</code>	模型输出、图表、指标、校准与各实验记录
<code>results/复现清单.json</code> 、 <code>q4_manifest.json</code> 等	随机种子、输入哈希与唯一复现命令