

NIPT 检测时点优化与异常标记判定模型

摘要

无创产前基因检测（NIPT）需要同时处理重复检测、达标概率、检测时点和异常标记判定。本文以附件中的男胎、女胎记录为对象，以孕妇代码为分组单位，建立可复现的主体层级建模框架。

对于问题一，在 Y 染色体浓度的 logit 尺度上建立随机截距线性混合模型，并以加性样条作非线性对照。孕周系数为 0.04701，BMI 系数为 -0.02446 ，组内相关系数为 0.7283；按孕妇留出的预测 $R^2 = -0.0302$ ，故将结果解释为群体关联而非个体预测承诺。

对于问题二，以 Y 浓度是否达到 4% 建立边际二项概率模型，并将失败风险和延迟代价结合为条件风险。动态规划在连续 BMI 上联合确定分群和检测时点。中延迟 M 情景给出 11 周、11 周 6 天、12 周 6 天的三组方案，对应样本人数为 200、25、42。

对于问题三，加入年龄、身高及孕产代理变量后，基础扩展模型 Brier 为 0.11192，较 Q2 高 0.00032，未显示稳定增益；因此保留问题二的简洁主线，并将多因素方案作为条件扩展。

对于问题四，对 T13、T18、T21 及任一异常标记分别拟合主体隔离的 L2 正则化 Logistic 模型。总体异常标记的 AP 为 0.3823、Brier 为 0.08419。除 MCC 阈值外，设置训练层 90% 灵敏度约束的漏诊优先方案；其外层总体灵敏度为 0.8955、特异度为 0.4033，展示漏诊与误报的权衡。

本文形成“重复测量解释—概率预测—风险决策—异常判定”的框架。结论仅适用于本附件、所列阈值与风险权重，不能替代临床确诊或独立队列验证。

关键词：NIPT；线性混合模型；主体隔离验证；动态规划；Logistic 回归

一、引言

NIPT 以母体外周血游离 DNA 为信息来源。男胎中，Y 染色体浓度不足可能导致结果不可报告；女胎中，异常标记判定面对类别不平衡与少数阳性样本。附件中同一孕妇常有多次检测，故不能将每一行默认为独立样本。本文解决四项任务：解释 Y 浓度的纵向关联；在风险条件下确定 BMI 分组与时点；判断多因素能否稳定改善该决策；以及在检测后特征条件下判定女胎异常标记。

二、总体分析

四问按信息可得性的时间顺序递进：问题一以男胎 Y 浓度为连续响应，建立含孕妇随机截距的纵向模型；问题二将浓度转化为达标事件，对新孕妇预测边际概率并作风险优化；问题三比较多因素扩展的主体留出表现；问题四使用检测后可得的测序特征做异常标记判定。所有性能评价按孕妇划分训练、测试，折外记录不参与填补、标准化、拟合或阈值选择。

三、模型假设

- 预约决策仅使用预约前或首条记录可得的信息，检测后质量变量不进入预约模型。
- 同一孕妇的未观测稳定差异由随机截距刻画，给定固定效应和随机效应后残差近似独立。
- 4% 为主分析浓度阈值，3.5% 和 4.5% 只用于敏感性分析；搜索孕周为 11 至 25 周。
- 问题四的异常标签为附件标记，供模型比较，不等同于临床确诊结局。

四、符号说明

表 1 主要符号说明

符号	含义
Y_{ij}	第 i 名孕妇第 j 次检测的 Y 染色体浓度
g_{ij}	检测孕周
b_i	孕妇 i 的随机截距
$p(t x)$	特征 x 下孕周 t 达到浓度阈值的边际概率
$R(t x)$	在孕周 t 检测的条件风险

符号	含义
λ, δ	每周延迟代价与 13 周起附加代价
q_i, h	女胎异常预测概率与分类阈值

五、数据审查与预处理

5.1 数据层级与样本结构

男胎工作表包含 1082 条测序记录、267 名孕妇；女胎工作表包含 605 条记录、147 名孕妇。男胎每位孕妇有 1 至 8 条记录，中位数为 4 条。同一孕妇可能在不同时间重复抽血，也可能在同次抽血下重复测序；前者同时包含随孕周变化和个体差异，后者更接近检测过程波动。图 1 显示重复记录数量，说明记录数不能直接当作独立样本量。

表 2 数据结构与阈值观测概况

项目	数值	建模含义
男胎记录 / 孕妇	1082 / 267	主体分组验证
女胎记录 / 孕妇	605 / 147	稀有标签与主体相关并存
男胎每人记录数	1-8, 中位数 4	不得假设独立同分布
Y 浓度达到 4%	937 条	达标记录占多数
Y 浓度低于 4%	145 条	保留为早检失败风险信号
首次观测已达标	217 名孕妇	首次达标时间左删失
观察到未达标转达标	43 名孕妇	事件仅能定位于区间
阈值反转	34 名孕妇	达标状态并非严格单调




图 1 男胎孕妇的重复记录数量分布

5.2 变量口径与信息泄漏防范

孕周统一为连续周数，即整数周加天数除以 7；优化输出再换回“周和天”。百分比变量统一为 0 至 1 比例，4% 对应 0.04。BMI 与身高、体重用于一致性审查，但不在小样本模型中无条件同时使用高度共线变量。原始附件不改写，派生变量全部由代码生成。

预约时点模型只能使用预约时已知信息。读段数、过滤比例、GC 含量等属于检测后信息，不进入 Q2 和 Q3。Q2 使用每位孕妇首条记录 BMI 作为预约前代理，Q3 使用相同基线时点的年龄、身高等变量；这避免将未来记录带入早期预约，但仍是回顾性代理。女胎异常任务不同：其输入在检测后判定时已可获得，故可以使用染色体统计量及测序质量特征。

六、模型的建立与求解

七、模型的建立与求解

7.1 问题一：Y 染色体浓度的重复测量模型

男胎数据含 267 名孕妇、647 条记录。将浓度比例作 logit 变换，主模型为

$$z_{ij} = \beta_0 + \beta_1 g_{ij} + \beta_2 \text{BMI}_{ij} + \beta_3 g_{ij} \text{BMI}_{ij} + b_i + \varepsilon_{ij}, \quad b_i \sim N(0, \sigma_b^2). \quad (1)$$

孕周系数为 0.04701、BMI 系数为 -0.02446 ，交互项没有稳定证据。组内相关系数 0.7283 表明主体层级不可省略。以孕妇为组作五折外层验证，主模型 $R^2 = -0.0302$ ；因此显著关联不被解释为对新个体的精确预测。




图 2 BMI 对 Y 染色体浓度的边际影响

7.1.1 系数解释、模型对照与结论边界

表 3 给出固定效应估计。孕周的 95% 区间为 $[0.04214, 0.05187]$ ，BMI 的 95% 区间为 $[-0.04018, -0.00874]$ ；孕周与 BMI 交互项区间跨零，故不把它解释为已经证实的调节机制。随机效应模型的条件拟合 R^2 约为 0.7890，但它使用了已观测孕妇的历史记录来估计其随机截距。该数值不能替代新孕妇的外层预测 R^2 。

表 3 Y 浓度混合模型的固定效应估计

项	系数	95% 区间	p 值
截距	-2.57364	$[-2.62810, -2.51918]$	—
中心化孕周	0.04701	$[0.04214, 0.05187]$	4.57×10^{-80}
中心化 BMI	-0.02446	$[-0.04018, -0.00874]$	0.00229
孕周 $\times$ BMI	0.00120	$[-0.00022, 0.00262]$	0.09680




图 3 孕周与 Y 染色体浓度的模型关联曲线

为检验线性设定，以低维自然三次加性样条替代线性孕周、BMI 项，仍保留孕妇随机截距；样条自由度仅在外层训练集内选择。表 4 显示样条的记录级误差略低，但主体平均误差差异很小，故保留线性混合模型作为主解释工具。它的优势是关系清晰，而不是宣称其个体预测充分准确。

表 4 问题一的新孕妇预测比较

模型	记录 RMSE	记录 MAE	记录 R^2	主体平均 RMSE
线性混合模型	0.51406	0.42321	-0.03023	0.50628
加性样条混合模型	0.50717	0.41598	-0.00278	0.50083

7.2 问题二：达标概率、风险函数与 BMI 分组

定义达标事件 $A_{ij} = I(Y_{ij} \geq 0.04)$ ，在 logit 连接下拟合随机截距二项模型。对新孕妇积分随机效应，得到边际达标概率：

$$p(t | x) = \int \text{logit}^{-1}\{\eta(t, x) + b\} \phi(b; 0, \sigma_b^2) db. \quad (2)$$

其中 x 为 BMI。对每日网格孕周计算条件风险

$$R(t | x) = 1 - p(t | x) + \lambda(t - 11) + \delta I(t \geq 13). \quad (3)$$

低延迟 L、中延迟 M、高延迟 H 分别取 $(\lambda, \delta) = (0.005, 0.10)$ 、 $(0.020, 0.10)$ 、 $(0.050, 0.10)$ 。本文选择 M 作为主答案：它同时保留失败和等待代价，避免 L 情景频繁出现 25 周边界解，也避免 H 情景将方案推向 11 周边界。

对 BMI 排序后，以动态规划最小化组内加权风险，约束最小组样本量、相同 BMI 不拆分和局部观测支持。表 5 给出 4% 阈值、M 情景的有效三组解；边界显示到一位小数，优化使用未舍入值。

表 5 问题二：4% 阈值、中延迟 M 情景下的条件方案

BMI 区间 (kg/m ²)	人数	推荐检测时点	说明
[20.7, 33.4)	200	11 周	搜索域下界
[33.4, 34.4)	25	11 周 6 天	满足最小组样本量
[34.4, 46.9]	42	12 周 6 天	13 周阶跃之前




图 4 不同孕周与 BMI 下的边际达标概率

7.2.1 概率验证、可行性与动态规划

真实首次达标周在附件中不能直接识别：217 名孕妇首次观测时已达标，43 名在随访中才观察到由未达标转达标，另有 34 名出现阈值反转。因此本问回答可观测问题“在某孕周的一次检测是否达标”，而不将首次观测时点误称为生理首次达标时点。

外层五折以孕妇分组；每名孕妇先平均其记录 Brier 损失，再跨孕妇平均，避免多次检测者权重过大。二项模型主体 Brier 为 0.11160，训练主体常数率基线为 0.11315，提升较小；校准图的高概率区域也存在一定乐观偏差。图 5 和图 6 分别展示 BMI 条件的概率曲线与早孕支持范围；不晚于 12 周的首次观测仅 69 名，故早期策略不能被解读为无条件外推。




图 5 不同 BMI 条件下的男胎达标概率曲线




图 6 男胎检测孕周与首次观测时点的支持范围

对排序后的主体，令 $C(a, b)$ 为第 a 至 b 名主体在共同检测时点下的最小加权风险。动态规划递推为

$$D(k, b) = \min_{a \leq b} \{D(k-1, a-1) + C(a, b)\}, \quad (4)$$

其中候选段必须满足最小主体数、相同 BMI 不拆分和局部观测支持约束。求解后将相邻且时点相同的段合并；保留无决策差异的切点只会制造“越分越细”的假象。全样本条件解与外层概率验证分别报告：前者给出题目要求的可执行方案，后者检验其概率基础的可推广程度。

7.3 问题三：多因素扩展与条件方案

基础扩展规格加入首条记录年龄、身高；完整规格再加入辅助受孕、孕次与产次代理。原体重、身高和 BMI 不同时输入基础规格，检测后质量变量不进入预约模型。三种规格采用相同主体五折划分，以每名孕妇的外层 Brier 损失作配对比较，见表 6。

表 6 多因素固定规格相对 Q2 的主体留出表现

规格	主体 Brier	相对 Q2 差值	差值 95% 区间
Q2: 孕周与 BMI	0.11160	0	—
基础扩展: 加入年龄、身高	0.11192	0.00032	[−0.00247, 0.00312]
完整扩展: 再加孕产代理	0.11384	0.00224	[−0.00132, 0.00596]

两种扩展均未显示稳定改善。基础扩展在 M 情景下仍按 BMI 分组，得到 [20.7, 33.4)、[33.4, 35.0)、[35.0, 46.9] 三组，推荐时点依次为 11 周、12 周 2 天、12 周 6 天；它是条件扩展结果，不替代问题二的主方案。

7.3.1 配对验证与测量误差敏感性

Q2、基础扩展和完整扩展使用相同的主体五折划分，故可对每名孕妇的外层 Brier 损失作配对比较。图 7 展示两种扩展相对 Q2 的误差差值；正值表示扩展模型更差。区间通过主体损失差值的重采样构造，描述已固定模型规格下的验证不确定性，而不包含反复搜索变量组合带来的全部不确定性。




图 7 多因素扩展相对 BMI 模型的主体配对误差

为评估测量不确定性，按孕妇、检测日期、抽血次数和孕周识别同次抽血重复测序组，共 18 组、14 名孕妇、每组两条记录。在 logit 浓度尺度上，以组内平方和除以自由

度估计波动方差：

$$\hat{\sigma}_m^2 = \frac{\sum_g \sum_{j=1}^{n_g} (z_{gj} - \bar{z}_g)^2}{\sum_g (n_g - 1)}. \quad (5)$$

得到 $\hat{\sigma}_m = 0.123745$ ；按 14 名孕妇进行 2000 次重采样，尺度区间为 $[0.08175, 0.16770]$ 。该值是同次抽血组内波动尺度，不是整个 NIPT 平台的仪器误差标准差。

从 267 名男胎孕妇有放回重采样，保留每位被抽中主体的全部记录；对 logit 浓度附加 $c\hat{\sigma}_m\xi_{ij}$ ，其中 $c \in \{0, 0.5, 1, 1.5\}$ ，再重新拟合、重新分组。共完成 20 轮、4 个噪声水平、2 种概率规格的 160 次拟合。表 7 显示低延迟情景下主体平均推荐孕周的实际范围；不同噪声水平的中位数并不单调，不能概括为“误差越大越应提前检测”。

表 7 低延迟情景下主体平均推荐孕周的 20 轮分布

模型	追加噪声倍数	中位数 / 周	实际范围 / 周
Q2	0	14.95	12.86–23.82
Q2	0.5	15.02	12.81–23.82
Q2	1.0	14.43	12.08–25.00
Q2	1.5	14.77	11.65–23.82
基础扩展	0	15.27	12.86–25.00
基础扩展	0.5	15.27	12.71–23.73
基础扩展	1.0	14.88	12.13–25.00
基础扩展	1.5	14.68	11.61–23.82

7.4 问题四：女胎异常标记概率判定

以 T13、T18、T21 及任一异常标记为四个二元目标，输入染色体 Z 值、X 浓度、GC、读段与比对质量、孕周、BMI、年龄等 14 项检测后特征。对每个目标拟合 L2 正则化 Logistic 模型：

$$q_i = \frac{1}{1 + \exp[-(\alpha_0 + \alpha^T v_i)]}, \quad \hat{A}_i = I(q_i \geq h). \quad (6)$$

采用三折分层主体外层验证；预处理、拟合和阈值选择均限制在训练主体内。MCC 阈值在内层主体预测上选择。另设高灵敏度方案：在训练层选择灵敏度至少 90% 的最高阈值，再由外层测试其可推广性。

总体异常标记的 AP 为 0.3823、Brier 为 0.08419、ROC-AUC 为 0.7711。MCC 阈值下总体灵敏度 0.1791、特异度 0.9851；高灵敏度方案的外层灵敏度 0.8955、特异度 0.4033。表 8 表明以大量假阳性换取较低漏诊风险，且 T21 仅有 12 名阳性主体，不能作临床高敏筛查承诺。

表 8 高灵敏度约束阈值的主体隔离外层结果

目标	阈值中位数	灵敏度	特异度	TP	FP	FN
T13	0.0199	0.9130	0.2612	21	430	2
T18	0.0605	0.8478	0.6315	39	206	7
T21	0.0058	0.8462	0.0726	11	549	2
任一异常	0.0562	0.8955	0.4033	60	321	7

7.4.1 标签结构、混淆矩阵与校准

T13、T18、T21 和任一异常目标的阳性记录数分别为 23、46、13、67，对应 18、30、12、44 名孕妇。图 8 显示少数阳性主体结构，尤其 T21 的验证不确定性较大。分类输入包括 13、18、21 和 X 染色体 Z 值、X 浓度、GC、读段与比对质量、检测孕周、BMI 和年龄共 14 项特征；类别权重未被用于模型训练，以避免未校准的代价调整被误作真实概率。




图 8 女胎各异常目标的阳性主体数量

MCC 阈值下，任一异常标记的 67 条阳性记录中识别 12 条、遗漏 55 条。表 9 给出各目标的外层混淆矩阵。由于类别不平衡，准确率不作为主要结论；AP、Brier 和校准比单一准确率更能表达概率与少数类表现。

表 9 各目标外层判定的混淆矩阵（MCC 阈值）

目标	真阳性 TP	假阳性 FP	假阴性 FN	真阴性 TN
T13	4	46	19	536
T18	23	81	23	478
T21	2	97	11	495
任一异常	12	8	55	530




图 9 女胎总体异常标记的外层概率校准

7.5 结果解释与时点决策

问题一中，随机效应引入的主体内相关性表明，常规逐行回归会错误放大有效样本量。图 10 比较线性混合模型和样条对照的外层表现：两者均未得到正的主体留出 R^2 ，因此选择线性混合模型作为关联解释的主模型，而不以复杂曲线追求表面拟合度。




图 10 问题一模型在主体留出验证中的比较

问题二的三组时点来自达标概率、风险权重和支持约束的共同作用，而非 BMI 本身的临床分类边界。图 11 显示主体留出概率校准情况；早孕及高 BMI 区域的支持较少，故策略不会在缺乏观测支持的区域作无约束外推。对不同风险权重，L 情景更重视等待、但会在部分组产生 25 周边界解；H 情景更重视延迟、因而倾向于 11 周边界。M 情景位于两者之间，故用于主答案。




图 11 问题二边际达标概率的主体留出校准

问题三的扩展模型将个人年龄、身高代入概率后仍只按 BMI 排序分组，并在组内对实际协变量分布的风险求和；这避免把所有人固定为平均年龄和身高。图 12 展示 M 情景下的扩展条件解以及 L/M/H 场景下的变化。由于表 6 的配对区间跨过零，正文不把它解释成对 Q2 的优越替代。




图 12 问题三多因素扩展下的 BMI 条件时点

7.6 问题四的判定口径

异常类比例低时，准确率可由预测全部正常而虚高，因此同时报告 ROC-AUC、AP、Brier、灵敏度、特异度与混淆矩阵。Brier 分数定义为

$$\text{Brier} = \frac{1}{N} \sum_{i=1}^N (q_i - A_i)^2. \quad (7)$$

对固定的外层预测，先在每名孕妇内平均损失，再跨主体作 2000 次重采样。T18 相对常数率的主体 Brier 差值为 -0.00929 ，区间为 $[-0.01685, -0.00294]$ ；任一异常标记的差值为 -0.01527 ，区间为 $[-0.02575, -0.00663]$ 。T13 和 T21 区间均跨过零，不能宣称稳定增益。




图 13 女胎各目标相对常数率的主体 Brier 差值区间

八、模型检验与分析

8.1 主体隔离验证

问题一的负外层 R^2 说明关联与预测应分开表述。问题二检验概率校准，问题三以同折损失差值比较，问题四使用嵌套主体隔离阈值选择。由此避免了同一孕妇的相似记录同时出现于训练集和测试集造成的性能高估。

8.2 阈值、风险与测量敏感性

同次抽血重复测序组给出 logit 浓度波动尺度 $\hat{\sigma}_m = 0.123745$ 。按孕妇 2000 次重采样的区间约为 $[0.08175, 0.16770]$ 。在 20 轮主体重采样及四档追加噪声下重新拟合和优化，策略随样本构成而变化，故 BMI 切点只代表本附件、当前代价下的条件分割。

表 10 Q2 低延迟 L 情景的阈值敏感性

浓度阈值	有效组数	内部 BMI 切点	检测时点	对应人数
3.5%	1	无	12 周 6 天	267
4.0%	2	33.8	12 周 6 天；25 周	212；55
4.5%	2	29.1	12 周 6 天；25 周	38；229

表 11 女胎主体隔离外层记录级指标（MCC 阈值）

目标	ROC-AUC	AP	Brier	灵敏度	特异度
T13	0.6796	0.1967	0.03317	0.1739	0.9210
T18	0.7943	0.2924	0.06252	0.5000	0.8551
T21	0.4467	0.0302	0.02123	0.1538	0.8361
任一异常	0.7711	0.3823	0.08419	0.1791	0.9851

九、模型的评价

模型将孕妇、抽血和测序记录分层，避免重复记录造成虚假的独立样本量；将浓度关联、达标概率和风险优化拆开，使每个推荐时点可追溯至阈值、权重及可行性约束；且预处理和阈值选择均在训练主体内完成。局限是风险权重未由真实临床效用标定，早孕、高 BMI 及稀有异常覆盖有限，异常标签也非确诊金标准。高灵敏度阈值必须以独立阳性队列重新验证。

十、模型的改进与推广

补充预约前基线信息、早孕独立队列、复检成本和确诊结局后，可在不改变主体层级验证与风险优化框架的前提下重新标定概率与代价。该方法可推广至复检预约、连续生理指标随访和筛查流程优化；推广时必须重新定义可用信息、事件阈值、主体单位和风险权重，不能直接移植本题 BMI 切点或分类阈值。

参考文献

- [1] Wang E, Batey A, Struble C, et al. Gestational age and maternal weight effects on fetal cell-free DNA in maternal plasma. *Prenatal Diagnosis*, 2013, 33(7): 662–666.
- [2] Laird N M, Ware J H. Random-effects models for longitudinal data. *Biometrics*, 1982, 38(4): 963–974.
- [3] Yang J, Ding X, Zhu W. Improving the calling of non-invasive prenatal testing on 13-/18-/21-trisomy by support vector machine discrimination. *PLOS ONE*, 2018, 13(12): e0207840.
- [4] Efron B. Bootstrap methods: Another look at the jackknife. *The Annals of Statistics*, 1979, 7(1): 1–26.

附录

表 12 论文支撑材料及可复现入口

文件	说明
src/run_paper_evidence.py	一键重建数值证据、图表和测试
src/q1_lmm_baseline.py	问题一随机截距线性混合模型
src/q2_probability.py	问题二边际达标概率和动态规划策略
src/q4_chromosomes.py	问题四主体隔离 Logistic 及高灵敏度阈值
outputs/	模型输出、图表、指标与高灵敏度结果